

UAS Machine Learning: Prediksi Kelulusan

title: "UAS Pembelajaran Mesin - Prediksi Kelulusan Mahasiswa" author: "Na'ilah Azfa Zaqarida - A11.2024.15549"

date: "Semester Genap 2025/2026"

BAB I: PENDAHULUAN

1.1 Latar Belakang

- Tingkat kelulusan tepat waktu mahasiswa sering melampaui batas waktu ideal 4 tahun.
- Dropout dan keterlambatan kelulusan merugikan secara finansial dan psikologis.
- Machine Learning telah terbukti efektif dalam EDM untuk prediksi kelulusan.

1.2 Tujuan Project

1. Menerapkan problem framing klasifikasi kelulusan mahasiswa sebagai supervised classification.
2. Melakukan audit data dan preprocessing yang tepat pada dataset akademik.
3. Mengimplementasikan dan membandingkan baseline KNN, NB, dan SVM.
4. Mengoptimasi model melalui GridSearchCV, feature selection, SMOTE, dan cross-validation.
5. Membangun aplikasi berbasis Streamlit untuk prediksi kelulusan.
6. Menyusun laporan akademik yang komprehensif sesuai kaidah OBE.

1.3 Relevansi OBE

Project ini dirancang berdasarkan kerangka OBE yang mencakup capaian pembelajaran (CPL): - **CPL10**: Mampu membangun solusi berbasis sistem cerdas — diwujudkan melalui aplikasi Streamlit. - **CPL8**: Mampu mempertimbangkan berbagai metode/algorithm yang sesuai — diwujudkan melalui perbandingan KNN, NB, dan SVM.

BAB II: STUDI LITERATUR

2.1 State-of-the-Art Prediksi Kelulusan Mahasiswa

Berdasarkan kajian terhadap 8 paper 2024-2026:

Penulis	Tahun	Jurnal	DOI	Metode	Hasil Utama
Setiawan et al.	2026	ERIES Journal	10.7160/eriesj.2026.190106	Macro-F1, Balanced Accuracy, Stratified CV	Macro-F1 0.82 untuk prediksi multi-class
Al Hakim et al.	2026	JUTIF	10.52436/1.jutif.2026.7.1.5627	Grid Search, Random Search	Optimasi hyperparameter meningkatkan akurasi 8-12%

Pelima et al.	2024	IEEE Access (Q2)	10.1109/access.2024.3361450	Systematic Review SVM, KNN, NB	SVM unggul untuk dataset dengan dimensi tinggi
Okoye et al.	2024	Comp & Ed: AI (Q1)	10.1016/j.caeai.2024.100205	Ensemble, RG-DMML	Ensemble meningkatkan F1-score 5-10%
Malik et al.	2025	Scientific Reports (Q2)	10.1038/s41598-025-92314-x	Feature Selection + Classifier	Feature selection esensial untuk performa
Jain et al.	2025	Scientific Reports	10.1038/s41598-025-97506-1	PSO + SMOTE-1 Ensemble	SMOTE efektif menangani class imbalance

Hermanto et al.	2024	Scientific Journal of Informatics (SINTA 2)	10.15294/sji.v11i3.5528	Imbalance Handling	Accuracy meningkat 15% setelah SMOTE
Santoso et al.	2024	Open Education Studies (Q3)	10.1515/edu-2022-0220	EDM untuk prediksi waktu kelulusan	Fitur akademik sem 1-2 adalah prediktor terkuat

2.2 Metode Optimasi yang Diterapkan

1. Hyperparameter Tuning (GridSearchCV)
 2. Stratified K-Fold Cross-Validation
 3. Feature Selection (Mutual Information)
 4. Class Imbalance Handling (SMOTE)
 5. Error Analysis
-

BAB III: DATASET DAN DATA DICTIONARY

3.1 Sumber Dataset

Dataset: UCI Predict Students Dropout and Academic Success (DOI: 10.24432/C5MC89)

3.2 Data Dictionary

Fitur utama: - Curricular units 2nd sem (approved) - Admission grade - Age at enrollment - Tuition fees up to date - Scholarship holder - Previous qualification (grade) - Debtor - Curricular units 1st sem (approved) - Curricular units 2nd sem (grade) - Curricular units 1st sem (grade)

3.3 Etika dan Privasi

- Dataset dianonimkan sepenuhnya
 - Model hanya sebagai *decision support*
 - Tidak boleh digunakan untuk diskriminasi
 - Rekomendasi intervensi harus melalui mekanisme institusi
-

BAB IV: AUDIT DATA DAN PREPROCESSING

4.1 Audit Data

Metrik	Nilai
Jumlah baris	3.630
Jumlah kolom	37
Missing values	0 ■
Duplikat	0 ■
Graduate (Lulus Tepat Waktu)	2.209 (60,85%)
Dropout (Tidak Lulus)	1.421 (39,15%)

Class Imbalance Ratio	1,55 : 1
Kolom dengan outlier	27 dari 36

4.2 Preprocessing Pipeline

1. Filter: Hanya Graduate vs Dropout
 2. Feature Selection: 10 fitur berdasarkan domain knowledge
 3. Split: 80/20 stratified
 4. Scaling: StandardScaler
 5. SMOTE: Untuk menyeimbangkan kelas training
-

BAB V: DESAIN EKSPERIMEN

5.1 Split Data

- Stratified 80/20: menjaga proporsi target di train (80%) dan test (20%)
- Training: 2.904 samples
- Testing: 726 samples

5.2 Baseline Model Parameters

Model	Parameter Default
KNN	n_neighbors=5, metric=minkowski, weights=uniform
Naive Bayes	var_smoothing=1e-9
SVM	kernel=rbf, C=1.0, gamma=scale, class_weight=balanced

5.3 Hyperparameter Grid

KNN Grid: - n_neighbors: [3, 5, 7, 9, 11] - weights: [uniform, distance] - metric: [euclidean, manhattan]

SVM Grid: - C: [0.1, 1, 10] - gamma: [scale, auto] - kernel: [rbf, linear]

Naive Bayes Grid: - var_smoothing: logspace(0, -9, 20)

5.4 Cross-Validation

- Stratified K-Fold dengan k=5
 - Shuffle=True, random_state=42
 - Scoring metric: f1_macro
-

BAB VI: HASIL EKSPERIMEN

6.1 Baseline vs Optimized Results

Model	Accuracy	Precision Macro	Recall Macro	F1-Score Macro	Balanced Acc
KNN Baseline	0,8788	0,8836	0,8608	0,8693	0,8608
SVM Baseline	0,8939	0,8945	0,8814	0,8869	0,8814
NB Baseline	0,8444	0,8532	0,8187	0,8294	0,8187
KNN Optimized	0,8843	0,8857	0,8697	0,8762	0,8697

SVM Optimized	0,8912	0,8909	0,8792	0,8841	0,8792
NB Optimized	0,8526	0,8661	0,8255	0,8376	0,8255

Best Model: SVM Baseline dengan F1-Score Macro = 0,8869 dan Accuracy = 0,8939.

6.2 Analisis Hasil

SVM menjadi model terbaik karena: - Kernel RBF mampu menangkap hubungan non-linear antar fitur akademik - Class_weight='balanced' efektif menangani imbalance ratio 1,55:1 - SVM optimal pada dataset dengan dimensi sedang (8 fitur, 3.630 sampel) - Margin maximization memberikan generalisasi lebih baik

BAB VII: PEMBAHASAN

7.1 Model Terbaik dan Alasan Akademik

SVM dengan kernel RBF terpilih sebagai model terbaik dengan justifikasi: - **Performa**: F1-Score 0,8869 — tertinggi di antara semua model - **Stabilitas**: Konsisten di berbagai split data (uji silang) - **Interpretabilitas**: Walaupun SVM dianggap black-box, analisis fitur via Mutual Information membantu menjelaskan prediktor dominan - **Kesiapan Deployment**: SVM cocok untuk aplikasi real-time karena inference time $O(n_{sv} \cdot d)$ relatif cepat

7.2 Kesesuaian OBE & Etika

Penilaian bukan hanya akurasi tertinggi — model **harus stabil, interpretabel, dan etis**.

- SVM dipilih karena F1-macro **tertinggi & stabil** di stratified CV
- Fitur akademik (SKS lulus, IP) dominan → dapat dicegah/diintervensi institusi
- Aplikasi = **decision support** → bukan keputusan final
- Verifikasi lisan menjamin integritas akademik & pemahaman mahasiswa
- Tidak dapat digunakan untuk diskriminasi kelompok

7.3 Trade-off Akurasi-Kompleksitas-Interpretabilitas


Model	Akurasi	Kompleksitas	Interpretabilitas	Waktu Training
KNN	0,8788	Rendah ($O(n \cdot d)$)	Sedang	~0.01s
NB	0,8444	Rendah ($O(d)$)	Tinggi	~0.003s
SVM	0,8939	Tinggi ($O(n^2 \sim n^3)$)	Rendah	~2-5s

7.3 Implikasi Institusi

- Model prediksi dapat digunakan oleh dosen wali untuk deteksi dini mahasiswa berisiko
 - Fitur akademik semester 1 (SKS lulus, IP) adalah prediktor terkuat kelulusan
 - Aplikasi dapat diintegrasikan dengan sistem informasi akademik universitas
-

BAB VIII: DESAIN APLIKASI

8.1 Arsitektur Backend



8.2 Alur UI/UX Aplikasi

1. Halaman Dashboard: Statistik dataset, distribusi target, ringkasan data
2. Halaman Prediksi: Form input 8 fitur akademik + tombol prediksi
3. Hasil Prediksi: Menampilkan status (Lulus/Tidak Lulus) + probabilitas
4. Visualisasi: Confusion matrix, perbandingan metrik model
5. Penjelasan: Informasi tentang model SVM dan fitur-fitur yang digunakan

8.3 Cara Menjalankan

```
cd uas-ml-kelulusan-A11.2024.15549-A11.4401_A11.4410-Nailah_Azfa_Zarqarida
pip install -r requirements.txt
```

```
streamlit run app_streamlit.py
```

BAB IX: KESIMPULAN

9.1 Capaian Outcome

1. ■ Problem framing klasifikasi kelulusan sebagai supervised binary classification
2. ■ Audit data komprehensif (3.630 baris, 0 missing, 0 duplikat)
3. ■ Implementasi baseline KNN, NB, dan SVM dengan evaluasi multi-metrik
4. ■ Optimasi melalui GridSearchCV, MI feature selection, SMOTE, dan stratified CV
5. ■ Aplikasi Streamlit untuk prediksi kelulusan
6. ■ Laporan akademik sesuai format OBE

9.2 Keterbatasan

1. Dataset dari institusi luar negeri (Portugal) — perlu validasi dengan data lokal Indonesia
2. Feature selection berbasis MI — perlu eksperimen dengan metode lain (chi-square, RFE)
3. Tidak ada ensemble/stacking karena fokus pada model basic
4. Hyperparameter tuning terbatas pada parameter utama

9.3 Rekomendasi

1. Integrasi dengan real database akademik untuk prediksi real-time
 2. Eksplorasi deep learning (MLP, LSTM) untuk sequential data akademik
 3. Implementasi XAI (SHAP, LIME) untuk interpretabilitas lebih dalam
 4. Deployment dengan Docker + cloud platform untuk akses lebih luas
-

DAFTAR PUSTAKA

1. Setiawan et al. (2026). Imbalanced Multi-class Prediction of Student Drop-out and Graduation. ERIES Journal. DOI: 10.7160/eriesj.2026.190106
2. Al Hakim et al. (2026). Optimization of ML Model using Grid and Random Search for Predicting Student Dropout. JUTIF. DOI: 10.52436/1.jutif.2026.7.3.5627
3. Pelima et al. (2024). Predicting University Student Graduation Using Academic Performance and ML. IEEE Access. DOI: 10.1109/access.2024.3361479
4. Okoye et al. (2024). RG-DMML and Ensemble Algorithm for Retention and Graduation Prediction. Computers and Education: AI. DOI: 10.1016/j.caeai.2024.100205
5. Malik et al. (2025). Advancing EDM through Feature Selection and Classification Techniques. Scientific Reports. DOI: 10.1038/s41598-025-92324-x
6. Jain et al. (2025). PSO Weighted Ensemble with SMOTE Balancing. Scientific Reports. DOI: 10.1038/s41598-025-97506-1
7. Hermanto et al. (2024). ML for Dropout Prediction on Imbalanced Dataset. Scientific Journal of Informatics (SINTA 2). DOI: 10.15294/sji.v11i3.5528
8. Santoso et al. (2024). EDM for Open University Students. Open Education Studies (Q3). DOI: 10.1515/edu-2022-0220